

FICHA TÉCNICA DO PROJETO

Análise Exploratória de Dados — SuperStore

18/05/2026 a 28/05/2026

1. Informações Gerais

Projeto	Análise Exploratória de Dados — SuperStore
Objetivo geral	Avaliar o desempenho operacional e financeiro da SuperStore, identificando oportunidades de melhoria em margem, logística e estratégia de descontos
Ferramenta principal	Python (Google Colab) + Looker Studio (Data Studio)
Período dos dados	2023 — 2024
Volumetria	19.960 linhas após tratamento (tabela unificada df_merged)
Responsável	Karinne do Nascimento Vieira

2. Objetivos da Análise

- Avaliar o impacto real das estratégias de desconto na margem de lucro
- Reduzir incertezas logísticas identificando quais modos de envio são mais rentáveis
- Identificar sinais precoces de sucesso ou prejuízo por produto, região e categoria
- Entender quais fatores (modo de envio, categoria, desconto) realmente impactam o desempenho financeiro

3. Ferramentas e Tecnologias

Linguagem	Python 3
Plataforma	Google Colab
Bibliotecas	Pandas, Matplotlib
Visualização	Looker Studio (Google Data Studio)
Formato dos dados	CSV (duas tabelas: Order e Shipping)

4. Contexto dos Dados

Fontes

Tabela Order	Dados de pedidos: clientes, produtos, categorias, vendas, lucro, desconto, prioridade, segmento, país, cidade
Tabela Shipping	Dados de envio: modo de envio, custo de frete, data de envio (opcional)
Chave de junção	order_id + product_id + shipment_line (chave composta)

Variáveis Principais

category	Categoria do produto (Furniture, Office Supplies, Technology)
profit	Lucro gerado pelo pedido
Sales	Valor total de vendas (contém 22 nulos — 0,11% dos dados)
discount	Desconto aplicado no pedido
shipping_cost	Custo de envio do pedido
ship_mode	Modo de envio (First Class, Second Class, Standard Class, Same Day)
order_priority	Prioridade do pedido (Critical, High, Medium, Low)
segment	Segmento do cliente (Consumer, Corporate, Home Office)
shipment_line	Contador de remessa por order_id + product_id (1 ou 2)
sales_missing	Flag: 1 quando Sales é nulo, 0 caso contrário

🌀 5. Processamento e Tratamento dos Dados

5.1 Conversão de Tipos

- Colunas order_date (tabela Order) e ship_date (tabela Shipping) convertidas de object para datetime usando pd.to_datetime

5.2 Valores Nulos

- Identificados 22 valores nulos na coluna Sales (0,11% dos dados)
- Padrão analisado por category, product_id e country — sem padrão sistêmico identificado (erros pontuais de entrada manual)
- Decisão: manter as linhas e criar coluna sales_missing (1 = nulo, 0 = preenchido) para permitir filtro nas análises de receita sem perder informações operacionais

5.3 Valores Duplicados

- 5 pares de duplicados exatos encontrados na tabela Order — mantidos porque tinham correspondência na tabela Shipping com custos de frete distintos

- Duplicados por `order_id` + `product_id` identificados em ambas as tabelas: não são erros, são split shipments (remessas divididas do mesmo pedido)
- Solução: criação da coluna `shipment_line` em cada tabela — contador que incrementa +1 a cada repetição de `order_id` + `product_id`
- Exceção: `order_id` = ES-2012-394-5862 + `product_id` = OFF-AR-10003066 (linhas 16125 e 18015) — clientes e cidades diferentes, provavelmente erro genuíno de entrada. Mantido para análises futuras

5.4 Padronização de Categóricas

- Nomes de `city` e `country` padronizados com `.str.lower().str.strip()`
- Substituições: 'br' → 'brazil', 'mx' → 'mexico' via `.replace()`

5.5 Valores Atípicos em Numéricas

- Analisadas as variáveis: `discount`, `profit`, `quantity`, `Sales` e `shipping_cost` com `.describe()`
- Valores negativos encontrados apenas em `profit` — estudados separadamente via método IQR
- 1.427 atípicos com lucro excepcionalmente baixo ou prejuízo identificados — mantidos para análise das causas operacionais

5.6 União das Tabelas

- Merge via: `df_merged = df_order_d1.merge(df_shipping, on=['order_id', 'product_id', 'shipment_line'], how='left')`
- Tabela Order: 19.960 linhas | Tabela Shipping: 19.960 linhas | Tabela merged: 19.960 linhas (sem explosão de linhas)
- Verificação pós-merge: nenhum novo nulo ou duplicado encontrado

6. Resultados e Conclusões

6.1 Desempenho por Categoria

- Technology: melhor margem (13,8%), maior lucro total (\$255k) — motor financeiro da operação
- Office Supplies: margem de 12,9% com ticket médio baixo (\$121) — eficiente logisticamente (frete médio \$12,74)
- Furniture: segunda em vendas (\$1,61mi) mas terceira em lucro (\$112k) — frete médio alto (\$45,10) + maior desconto médio (0,17)

6.2 Impacto do Desconto

- Correlação desconto × lucro: -0,341 (negativa moderada) — desconto é o principal fator de erosão de margem
- Correlação frete × lucro: +0,361 (positiva) — frete alto acompanha produtos caros, não causa prejuízo sozinho
- Com desconto > 20%: todos os modos de envio entram no vermelho (lucro médio negativo entre -\$68 e -\$78)

6.3 Logística e Modos de Envio

- Regra operacional identificada: pedidos Critical nunca usam Standard Class; pedidos Low usam exclusivamente Standard Class
- Same Day + Medium priority: melhor relação lucro/frete do dataset (\$52,76 de lucro médio com \$26,51 de frete)
- First Class + Critical: frete médio de \$65,16 contra lucro médio de \$29,32 — frete vale mais que o dobro do lucro

6.4 Produtos com Prejuízo

- 718 produtos com lucro médio negativo identificados
- Maiores prejuízos: Cubify CubeX 3D Printer (-\$2.640), Cisco TelePresence EX90 (-\$1.811), GBC DocuBind P400 (-\$1.320)
- Padrão: linhas inteiras de produto com prejuízo recorrente (Chromcraft, Bevis, Lesro em Furniture; GBC, Rogers em Office Supplies)

6.5 Análise Geográfica (países com volume mínimo de 100 pedidos e \$50k em vendas)

- Margem líquida negativa: Philippines (-21,85%), Dominican Republic (-18,40%), Italy (-8,40%), Indonesia (-8,01%), New Zealand (-2,61%), Brazil (-1,69%)
- United States: maior mercado (\$954k) com margem líquida de apenas 1,17% — risco oculto de alta magnitude
- Melhores margens: Cuba (14,62%), United Kingdom (12,77%), El Salvador (11,61%), China (9,84%), India (9,75%)

6.6 Segmentos de Clientes

- Consumer, Corporate e Home Office apresentam comportamento de compra muito similar em categoria, modo de envio e ticket médio
- Não há base para estratégias diferenciadas por segmento — o problema de margem afeta todos igualmente

6.7 Sazonalidade

- Queda consistente em julho nos dois anos (~46% abaixo de junho) — comportamento estrutural, não anomalia
- Dois picos anuais: junho e setembro-dezembro (fim do ano é o mais forte)
- Desconto médio de julho não cai — a queda é de demanda, não de preço

7. Recomendações de Negócio

Urgente

- Implementar regra de aprovação para descontos acima de 20% — principal alavanca de recuperação de margem
- Revisar viabilidade da operação em Philippines, Dominican Republic e Italy
- Descontinuar ou reprimir SKUs Chromcraft, Bevis e Lesro com prejuízo recorrente em Furniture

Importante

- Monitorar margem líquida dos Estados Unidos — 1,17% após frete sobre \$954k em vendas é uma fragilidade estrutural
- Revisar política de frete para pedidos Critical — custo logístico (\$65) quase dobra o lucro (\$29) em First Class
- Estabelecer frete mínimo ou preço mínimo para itens grandes de Furniture

Oportunidades

- Usar China, India e United Kingdom como benchmark — boa margem com volume relevante
- Proteger margens de Technology — é o motor financeiro e qualquer desconto agressivo tem alto impacto
- Usar julho como mês de eficiência operacional, não de promoções — a queda é de demanda estrutural

8. Limitações e Próximos Passos

Limitações

- Não confirmado se profit já desconta frete — margem líquida pode estar subtraindo frete duas vezes
- Ausência de CMV (custo do produto) — impossível calcular margem bruta real
- Sem dados de satisfação do cliente — impacto das decisões logísticas na experiência não pode ser medido

- Apenas 2 anos de dados — sazonalidade e tendências precisariam de mais histórico para conclusões definitivas
- Split shipments representam apenas 0,1% dos dados (16 casos) — estatisticamente irrelevante para análise de causalidade

Próximos Passos

- Confirmar metodologia de cálculo do campo profit com a equipe de dados
- Obter dados de custo do produto (CMV) para calcular margem bruta real
- Expandir histórico para 3-5 anos para confirmar sazonalidade
- Construir modelo preditivo de risco de prejuízo por produto + país + desconto

9. Links de Interesse

Dashboard Looker Studio	https://datastudio.google.com/reporting/644df4f9-da60-4404-bac8-27dec05b7275
Cálculos do Google Colab	https://colab.research.google.com/drive/1hVHSnjbQvDEb6jucfe1L19WELAIM539g?usp=sharing